

Desenho e Análise de Experimentos

em Ciências Sociais Aplicadas

Prof. Dr. Leonardo Vils

Programa de Pós-Graduação em Administração

Personagens desta aula

Odin Dinho Mestre dos Métodos

ThorMento Caos e Atalhos

Huginn Pensamento Crítico

Muninn Memória e Definições

AULA 1

Fundamentos e Desenho Experimental

Causalidade • Casos Reais • Tipos de Desenho • Validade

Roteiro

Bloco 1: Causalidade (~40 min)

Bloco 2: Casos Reais (~50 min)

Bloco 3: Tipos de Desenho (~50 min)

Bloco 4: Validade e Ameaças (~40 min)

AULA 1 — BLOCO 1

Causalidade

Por que o experimento é o rei dos métodos?

Por que Experimentos?

O único método que permite inferência causal por desenho

1. Covariação

X e Y variam juntos.
Survey e correlação
também mostram isso.

2. Precedência

X antecede Y no tempo.
Longitudinal também
consegue demonstrar.

3. Eliminação

Nenhuma variável Z explica
a relação $X \rightarrow Y$.
Só o experimento garante
isto via randomização.

ThorMento

"Correlação basta, Odin! Se os dados mostram relação, pronto!"

Odin Dinho

"Correlação sem controle é adivinhação com diploma. A randomização elimina o que você nem sabia que existia."

Correlação $\neq$ Causalidade

Por que X e Y podem covariar sem que X cause Y

Terceira Variável

Z causa tanto X quanto Y.

Ex: aldeias com mais templos
a Odin têm colheitas maiores.

Mas aldeias MAIORES constroem
mais templos E cultivam
mais terra.

Causalidade Reversa

Y causa X, não o contrário.

Ex: clientes satisfeitos
recomendam a loja.

A recomendação veio
da satisfação, não
o contrário.

Mediadora Oculta

$X \rightarrow M \rightarrow Y$ mas M é
outra coisa.

Ex: treinamento $\rightarrow$
confiança $\rightarrow$ desempenho.
Sem medir M, você
perde o mecanismo.

Huginn

"Antes de aceitar qualquer relação causal, pergunte: existe uma terceira variável? A direção pode ser inversa?"

O Problema Fundamental da Inferência Causal

Nunca observamos o que TERIA acontecido

Resultados Potenciais (Rubin)

$Y_i(1)$ = resultado com tratamento

$Y_i(0)$ = resultado sem tratamento

Efeito causal = $Y_i(1) - Y_i(0)$

Mas só observamos UM dos dois!

A Solução: Randomização

Se a alocação é aleatória:

$E[Y | \text{tratamento}] - E[Y | \text{controle}]$

= efeito causal MÉDIO (ATE)

A diferença de médias É o
estimador não-viesado do efeito.

SUTVA — Dois Pressupostos Silenciosos

1. Não-interferência: o tratamento de um participante NÃO afeta o resultado de outro.

2. Uma versão do tratamento: não há variações ocultas na implementação.

Violações: redes sociais, sala de aula, A/B tests com spillover.

Rubin, ATE e SUTVA

Quem são e o que significam esses termos do slide anterior

Donald Rubin

Estatístico de Harvard que formalizou nos anos 1970 o Potential Outcomes Framework — a linguagem matemática que usamos para definir efeito causal. Seu modelo é a base de praticamente toda inferência causal moderna.

ATE

Average Treatment Effect.
Efeito causal MÉDIO na população.
É a diferença entre o que aconteceria se TODOS recebessem o tratamento vs. se NINGUÉM recebesse.
A randomização permite estimá-lo.

SUTVA

Stable Unit Treatment Value Assumption. Dois pressupostos:

1. Não-interferência: o tratamento de A não afeta B.
2. Uma versão: a manipulação é igual para todos no mesmo grupo.

Anatomia de um Experimento

Variável Independente

O que o pesquisador manipula. Cria as condições experimentais.

Variável Dependente

O que se mede como resultado. Comportamental, atitudinal ou fisiológica.

Grupo Controle

Condição de referência. Passivo, ativo (placebo) ou linha de base.

Randomização

Alocação aleatória. Garante equivalência dos grupos.

Manipulation Check

Verificação de que a manipulação ativou o construto pretendido.

Covariáveis

Variáveis medidas para reduzir ruído e aumentar poder.

Identificando Causalidade

Em grupos de 3-4, analisem cada cenário e respondam:

(a) Há relação causal? (b) Quais das 3 condições são satisfeitas? (c) O que pode dar errado?

Cenário A: "Aldeias que sacrificam mais bois a Odin têm colheitas maiores."

Cenário B: "Guerreiros que bebem hidromel antes da batalha lutam mais bravamente."

Cenário C: "O Jarl randomizou metade das aldeias para usar arado de ferro e metade para usar arado de madeira. Mediu a colheita ao final da estação."

Para cada cenário: qual é a VI, a VD, e o potencial confound?

AULA 1 — BLOCO 2

Três Casos Reais

Experimentos de verdade — do restaurante ao churrasco

Caso 1: Balas e Gorjetas

Dar balinhas junto com a conta aumenta as gorjetas?

O Problema

Um restaurante quer saber se dar balas junto com a conta aumenta as gorjetas.

VI: Presença de bala (sim/não)

VD: Valor da gorjeta

Desenho: Between-subjects

Dia da semana (almoco/jantar)

Variáveis Estranhas
Tipo de cliente

Cardápio do dia

Encontros românticos

(covariável — gorjetas maiores!)

Não podemos dar bala para uns clientes e não dar para outros na mesma mesa!

Huginn

"Como sistematizar a exposição ao estímulo sem criar constrangimento entre clientes?"

Caso 1: O Desenho Experimental

Alternância semanal para controlar variáveis estranhas

Dia	Sem 1 Almoço	Sem 1 Jantar	Sem 2 Almoço	Sem 2 Jantar
Terça	Bala	Bala	Sem Bala	Sem Bala
Quarta	Sem Bala	Sem Bala	Bala	Bala
Quinta	Bala	Bala	Sem Bala	Sem Bala
Sexta	Sem Bala	Sem Bala	Bala	Bala
Sábado	Bala	Bala	Sem Bala	Sem Bala
Domingo	Sem Bala	Sem Bala	Bala	Bala

Controle

Variáveis estranhas mantidas constantes. Teste t independente para comparar médias de gorjetas entre os dias com bala vs. sem bala. Desenho 2×1 (com/sem bala), between-subjects.

Caso 2: Teste Cego de Açúcar

Um fabricante quer testar dois tipos de açúcar — as pessoas notam diferença?

Desenho Within-Subjects

40 famílias provaram dois bolos:
Bolo X (açúcar novo) e Bolo Y
(açúcar convencional).

Metade começou por X,
metade começou por Y.

Ninguém sabia qual era qual.

VD: sabor, maciez, textura
(escala de avaliação)

Controles Rigorosos

Bolos do MESMO sabor,
tamanho e forma
Sem cobertura ou calda
Servidos à temperatura ambiente e em pratos iguais

Fome controlada pelo tempo desde a última refeição

Ordem aleatorizada
(counterbalancing)

Muninn

"Within-subjects: cada participante é seu próprio controle. Análise com teste t dependente."

Caso 2: O que Aprendemos

Elementos essenciais deste experimento

Teste Cego

Participantes não sabiam qual açúcar era qual.

Elimina viés de expectativa.

É a versão experimental do "placebo".

Counterbalancing

Metade começa por X, metade por Y.

Controla efeitos de ordem: prática, fadiga, saciedade.

Essencial em designs within-subjects.

Análise

Teste t dependente (pareado).

Cada família comparada consigo mesma.

Mais poder com menos N do que between-subjects.

Variações Possíveis

E se quiséssemos testar 1, 2 ou 3 balas? Ou dois tipos de açúcar em três receitas diferentes? Passamos de 2×1 para designs fatoriais — e aí entra a ANOVA.

Caso 3: Gás vs. Carvão — Percepção Sensorial

As pessoas percebem diferença entre carne preparada no gás e no carvão?

Desenho 3×2 Fatorial

3 cortes: fraldinha, alcatra, picanha
2 métodos: gás (X) vs. carvão (Y)

Participantes NÃO sabiam o significado de X e Y.

Within-subjects: cada pessoa avaliou todos os cortes e métodos.

110 participantes

93 avaliações completas

(37% mulheres, 63% homens)

Variáveis

VD (6 critérios + geral):

Aparência, Aroma, Facilidade de Cortar, Maciez, Textura, Sabor

Variáveis de controle:

Temperatura da carne

Ponto da carne

Moderador testado:

Expertise declarada

(conhecimento de cortes de churrascos)

Caso 3: Procedimento

Ordem de avaliação com counterbalancing por corte

Fraldinha

1. Provar Gás → Avaliar
2. Provar Carvão → Avaliar
3. Comparar Gás vs. Carvão

Escala: 1 (péssimo)
a 5 (ótimo)

Avaliação via app
(Mentimeter) — on-line
e em tempo real.

Alcatra

1. Provar Carvão → Avaliar
2. Provar Gás → Avaliar
3. Comparar Carvão vs. Gás

Ordem invertida em
relação à fraldinha
(counterbalancing
entre cortes).

Picanha

1. Provar Carvão → Avaliar
2. Provar Gás → Avaliar
3. Comparar Carvão vs. Gás

Expertise medida:
- Conhecimento de cortes
- Conhecimento de
churrascos (1-3)

Resultados: Fraldinha

Diferenças estatisticamente significantes marcadas em destaque

Critério	Gás (X)	Carvão (Y)
Aparência	4,1	4,4
Aroma	3,9	4,5
Corte	3,8	3,8
Maciez	3,7	3,9
Textura	3,8	4,1
Sabor	3,9	4,3
MÉDIA	3,9	4,2

Moderação por Expertise

A expertise do avaliador moderou alguns resultados.

Avaliadores de BAIXA expertise:
Menor discriminação entre métodos de preparo.

Avaliadores de ALTA expertise:
Diferenças mais pronunciadas em aroma e sabor.

Huginn

"Carvão levou vantagem significativa em aparência, aroma, textura e sabor. A expertise modera o efeito!"

Resultados: Alcatra e Picanha

Controlando temperatura e ponto da carne

Alcatra	Gás	Carvão	Com controle Temperatura	Com controle Ponto
Aparência	3,8	4,1	3,9 vs 4,3	3,9 vs 4,1
Aroma	3,6	3,9	3,8 vs 4,0	3,8 vs 3,9
Sabor	3,7	4,0	3,8 vs 4,1	3,7 vs 4,0
MÉDIA	3,7	4,0	3,8 vs 4,1	3,7 vs 4,0

Picanha	Gás	Carvão	Resultado
Geral	4,0	3,9	Sem diferença significativa
Com controle temp.	4,1	4,0	Sem diferença significativa
Expertise alta	4,1 vs 3,9		Diferenças pontuais por expertise

Odin Dinho

"Picanha não mostrou diferença! O tipo de corte modera o efeito do método — isso é uma interação."

Caso 3: Lições Metodológicas

O que o churrasco nos ensina sobre desenho experimental

Within-Subjects

Cada participante avaliou
TODOS os cortes e métodos.

Vantagem: elimina variação
individual no paladar.

Controle: counterbalancing.

Fatorial 3×2

Permite testar INTERAÇÃO:
o efeito do método depende
do corte. Fraldinha diferencia,
picanha não.

Sem fatorial, perdemos isso.

Variáveis de Controle

Temperatura e ponto da carne
como covariáveis.

Expertise como moderador.

Análise mais limpa e interpretação
mais rica.

Da Cozinha para a Ciência

Esse experimento tem TODOS os ingredientes de um estudo publicável: manipulação cuidadosa, controle de variáveis estranhas, counterbalancing, teste cego, análise de moderação. A lógica é a mesma para marketing, gestão ou finanças.

Desenhando seu Experimento

Em grupos, planejem um dos experimentos abaixo:

Opção A: O Jarl de Hedeby quer aumentar a arrecadação de impostos.

Duas ideias: (A) cobradores simpáticos vs. intimidadores

(B) oferecer ou não desconto por pagamento antecipado

Opção B: Um restaurante quer testar se a música ambiente (jazz vs. pop vs. sem) afeta o ticket médio.

Respondam:

1. Qual é o desenho? (Between, within, fatorial?)
2. Quantas células? Quantos participantes por célula?
3. VI(s), VD, covariáveis, variáveis de controle
4. Manipulation check: como verificar a manipulação?
5. Duas ameaças à validade interna e como mitigá-las

Intervalo — 15 minutos

Aproveitem para discutir com os colegas!

AULA 1 — BLOCO 3

Tipos de Desenho

Between, within, fatorial e mixed — qual usar?

Between-Subjects (Grupos Independentes)

Cada participante vê apenas UMA condição — como no caso das Balas

Vantagens

- Sem efeitos de carryover
- Sem fadiga
- Procedimento mais simples
- Ideal quando manipulação é irreversível ou reveladora

Desvantagens

- Requer MAIS participantes
- Diferenças individuais viram ruído
- Variância de erro maior
- Exige randomização cuidadosa

Análise

- Teste t independente (2 grupos)
- ANOVA one-way (3+ grupos)

Caso Real

Balas e gorjetas: cada turno/dia era com ou sem bala.
Nenhum cliente recebeu ambas.

Muninn

"Between = cada um só vê uma condição. Análise: teste t independente ou ANOVA one-way."

Within-Subjects (Medidas Repetidas)

Cada participante passa por TODAS as condições — como no açúcar e no churrasco

Vantagens

- Cada um é seu próprio controle
- Elimina variabilidade entre-sujeitos
- Requer MENOS participantes
- Maior poder estatístico

Desvantagens

- Efeitos de ordem (prática, fadiga)
- Carryover entre condições
- Demand characteristics
- Nem sempre viável

Counterbalancing

- AB vs. BA (simples)
- Latin Square (3+ condições)
- Reportar SEMPRE a estratégia.

Casos Reais

- Açúcar: metade começou por X.
- Churrasco: ordem alternada entre cortes.

Huginn

"Within = todos passam por tudo. Análise: teste t dependente ou ANOVA de medidas repetidas."

Latin Square e Counterbalancing

Técnicas para controlar efeitos de ordem em designs within-subjects

Counterbalancing

Aleatorizar a ORDEM em que os participantes passam pelas condições.

Ex: metade prova bolo X primeiro, metade prova bolo Y primeiro.

Controla fadiga, prática e saciedade.

Simples (AB/BA) para 2 condições.

Latin Square

Para 3+ condições, um arranjo onde cada condição aparece em cada posição exatamente uma vez.

3 condições → 3 ordens: ABC, BCA, CAB

No churrasco: ordem dos cortes poderia variar entre participantes.

Tipos de Desenho: Comparação

Desenho	Lógica	Vantagem	Exemplo Real
Between	1 participante = 1 condição	Sem carryover Sem fadiga	Balas e gorjetas (com/sem bala)
Within	1 participante = todas condições	Mais poder Menos N	Açúcar e bolo (X vs. Y)
Fatorial	2+ fatores cruzados	Testa interações Eficiente	Churrasco 3x2 (corte × método)
Mixed	Combina between e within	Flexível Comum em pré-pós	Treinamento: tipo (B) × tempo (W)
Quasi	Sem randomização completa	Viável quando não há alternativa	Turmas da manhã vs. noite

O Fatorial e a Interação

Quando o efeito de A depende do nível de B — o coração do churrasco

Sem Interação (Linhas Paralelas)

O efeito de A é o mesmo em todos os níveis de B.

Interprete os efeitos principais tranquilamente.

Interação Significativa

O efeito de A DEPENDE de B.

Ordinal: efeito nos dois, mas com intensidades diferentes.

Disordinal: efeito se INVERTE!

Churrasco na Prática

No caso 3×2 (corte × método de preparo):

Fraldinha: carvão >> gás (diferença significativa em 4 de 6 critérios)

Alcatra: carvão > gás (diferença menor, moderada por temperatura/ponto)

Picanha: gás ≈ carvão (sem diferença significativa)

Isso é uma interação: o efeito do método depende do corte. Efeito principal isolado seria ENGANOSO.

Randomização: A Arma Secreta

O mecanismo que distribui TODOS os confounds — conhecidos e desconhecidos

Tipo	Lógica	Quando Usar	Cuidado
Simple	Cada participante alocado aleatoriamente	N grande, poucas condições	Pode desbalancear com N pequeno
Em Blocos	N igual por condição dentro de blocos	A maioria dos experimentos	Requer definir tamanho do bloco
Estratificada	Randomização separada por estratos	Variável de confusão conhecida	Perde poder se muitos estratos
Cluster	Randomiza grupos, não indivíduos	Turmas, lojas, cidades	Análise deve considerar cluster

Munn

"Randomização simples pode desbalancear com N pequeno. Prefira blocos na maioria dos casos."

AULA 1 — BLOCO 4

Validade e Ameaças

O que pode dar errado e como proteger seu experimento

As Quatro Dimensões da Validade

1

Validade Interna

A manipulação causou o efeito?
O *sine qua non*.
Sem ela, nada mais importa.

2

Val. de Construto

As medidas capturam os construtos teóricos?
Manipulation check + escalas.

3

Validade Externa

Os resultados generalizam?
População, contexto, tempo.
Não sacrificar a interna.

4

Val. Estatística

Análise permite inferências corretas? Power, pressupostos, effect sizes com CIs.

Odin Dinho

"Priorize a validade interna. Discuta a externa com nuance na discussão. Campo ganha em generalização, perde em controle."

Ameaças à Validade Interna

Cada uma é um truque que ThorMento usa para sabotar seu experimento

Ameaça	O que acontece	Como mitigar
História	Evento externo entre medidas	Grupo controle concorrente
Maturação	Mudança natural com o tempo	Período curto + controle
Testing	Pré-teste afeta pós-teste	Solomon four-group
Instrumentação	Mudança no instrumento	Padronização rigorosa
Regressão à média	Extremos regridem ao centro	Randomização
Seleção	Grupos pré-diferentes	Randomização (central)
Mortalidade	Perda diferencial	Análise de attrition, ITT
Difusão	Controle acessa tratamento	Isolamento entre condições

Solomon Four-Group e ITT

Termos da tabela de ameaças que merecem explicação

Solomon Four-Group Design

Richard Solomon (1949) propôs um desenho com 4 grupos para isolar o efeito do pré-teste:

G1: pré + tratamento + pós

G2: pré + controle + pós

G3: tratamento + pós (sem pré)

G4: controle + pós (sem pré)

Se $G1 \neq G3$, o pré-teste interfere.

ITT (Intention-to-Treat)

Princípio de análise: todos os participantes são analisados no grupo ao qual foram ALOCADOS, mesmo que tenham desistido ou trocado de grupo.

Protege contra viés de mortalidade.
Se 30 de 100 desistem do tratamento intensivo, excluí-los infla o efeito.
ITT mantém a integridade da randomização original.

Ameaças na Prática: Nos Nossos Casos Reais

Balas — Seleção?

Não houve randomização completa dos clientes.
Solução: alternância semanal controla variáveis temporais.

Açúcar — Demand Char.?

Se participantes percebem que estão sendo testados, podem alterar respostas. Teste cego mitiga.

Churrasco — Carryover?

Provar um corte pode afetar a avaliação do próximo (saciedade).
Counterbalancing parcial mitiga.

Geral — Mortalidade

Dos 110 participantes do churrasco, 17 não completaram.
Os que ficaram podem ter perfil diferente (mais motivados).

Odin Dinho

"Nenhum experimento é perfeito. A meta é minimizar ameaças e ser TRANSPARENTE sobre as limitações."

Caça às Ameaças

Leiam o experimento abaixo e identifiquem TODAS as ameaças à validade:

"Um professor testou um novo método de ensino de estatística. Usou suas turmas da manhã (método novo) e turmas da noite (método tradicional). Aplicou um pré-teste no início do semestre e um pós-teste no final. O pré-teste era idêntico ao pós-teste. Alunos da manhã faltaram menos. Resultado: turma da manhã teve nota 18% maior no pós-teste. Conclusão dos autores: o método novo funciona."

Identifiquem:

1. Pelo menos 4 ameaças à validade interna (com justificativa)
2. Pelo menos 1 ameaça à validade de construto
3. Pelo menos 1 limitação de validade externa
4. Proponham um redesenho que corrija os problemas principais

Lição dos Corvos — Aula 1

Muninn — O que levar daqui

Experimento = único caminho para causalidade

As 3 condições: covariação, precedência, eliminação

Randomização distribui TUDO (conhecido e desconhecido)

Três casos reais:

Balas (between), Açúcar (within), Churrasco (fatorial 3×2)

Validade interna primeiro, externa com nuance

Huginn — Desafios para vocês

Para a próxima aula, tragam:

1. Uma hipótese causal da sua pesquisa
2. Um desenho experimental para testá-la
3. Três ameaças à validade interna e como mitigá-las
4. Estimativa do N necessário (pode ser aproximada)
5. Qual é o tipo de design? (between, within, fatorial?)

AULA 2

Da Teoria Evolucionista à Análise de Dados

Psicologia Evolucionista • Motivações Românticas • CLT • ANOVA • Effect Sizes

Roteiro

Bloco 5: Ponte Evolucionista (~40 min)

Bloco 6: Dois Experimentos (~50 min)

Bloco 7: Análise na Prática (~50 min)

Bloco 8: ES, Reporting e Ética (~40 min)

AULA 2 — BLOCO 5

Uma Reflexão Evolucionista

Do maximizador de utilidades ao Nudge — e além

A evolução pela seleção natural só vale do pescoço para baixo?

Herdeiros de economistas defuntos (Keynes)?

Ainda somos os mesmos e vivemos como nossos pais (Belchior)?

O homo sapiens vai às compras com uma mente moldada em um ambiente de caçadores e coletores.

Psicologia Evolucionista

Unificando Teoria da Evolução e Psicologia Cognitiva

Módulos Mentais

Algoritmos e heurísticas forjados
por problemas recorrentes no passado evolutivo:

Selecionar e manter pares
Cuidar da prole
Formar alianças e ganhar status
Evitar doenças

Tudo em função de: Sobrevivência e Reprodução

Um novo olhar para vieses

O "falso positivo" evolutivo: fugir sem razão é mais benéfico
do que não fugir quando necessário.

Vocês são frutos do falso positivo!

Um viés de hoje é decorrente de algo que contribuiu para
a sobrevivência no passado.

Racionalidade Profunda.

Huggin

*"Se módulos mentais moldam decisões, o comportamento do consumidor pode ter raízes evolucionistas.
Testável!"*

Investimento Parental e Sinalização Custosa

Robert Trivers + Zahavi — as bases teóricas do experimento a seguir

Teoria do Investimento Parental

Robert Trivers (1972)

O sexo que investe MAIS na prole é mais SELETIVO na escolha de parceiros.

O sexo que investe MENOS compete mais intensamente pelo acesso ao outro.

Implicação: estratégias de curto vs. longo prazo diferem.

Sinalização Custosa (Handicap)

Zahavi (1975)

Sinais honestos são CUSTOSOS: difíceis de falsificar.

Correr riscos pode ser um sinal de qualidade genética.

O risco como "display": "Posso me dar ao luxo de arriscar porque sou apto."

Isso gera hipóteses testáveis!

Odin Dinho

"Teoria evolucionista gera hipóteses específicas e testáveis experimentalmente. Vamos ver como."

AULA 2 — BLOCO 6

Dois Experimentos

Motivações Românticas e Distanciamento Psicológico

Motivações Românticas e Risco

Quando módulos mentais de acasalamento são ativados, corremos mais risco?

Hipóteses de Risco

H1: Expostos a motivações românticas de curto prazo, HOMENS preferem atividades esportivas mais arriscadas do que aqueles expostos a motivações de longo prazo.

H2: Expostas a motivações românticas de curto prazo, MULHERES preferem atividades esportivas mais arriscadas do que aquelas expostas a motivações de longo prazo.

Manipulação (Cenário)

"Seu último dia de férias em um resort numa ilha paradisíaca. A festa na boate do hotel..."

Curto prazo: encontro casual, romance de uma noite.

Longo prazo: encontro que leva a um relacionamento sério.

Medida (VD)

Após o cenário, os participantes escolhiam uma atividade esportiva ao ar livre.

Atividades ranqueadas por risco: desde caminhada (baixo risco) até bungee jumping (alto risco).

Design: 2 (prazo) × 2 (gênero), between-subjects.

Resultados: Risco e Motivação Romântica

A interação entre prazo e gênero na escolha de atividades arriscadas

Padrão de Resultados

CURTO PRAZO:

Homens → Maior risco

Mulheres → Maior risco

LONGO PRAZO:

Homens → Menor risco

Mulheres → Menor risco

A motivação de curto prazo ativa módulos de exibição (display) em ambos os sexos.

Consistente com Trivers e Zahavi.

Teste Estatístico

Teste t independente para cada gênero (curto vs. longo).

Efeito de interação testado via ANOVA 2×2.

Implicação Teórica

Prova social, conformidade, assunção de risco — tudo pode ser dependente da relação entre módulos mentais e o problema adaptativo em questão.

Huginn

"A prova social ou conformidade social podem ser DEPENDENTES da relação entre módulos mentais e o problema!"

Diferenciação vs. Conformidade

A motivação romântica muda a preferência por mensagens de diferenciação ou conformidade?

Hipóteses de Comunicação

H3: Expostos a motivações de curto prazo, ao avaliarem mensagens promocionais de atividades esportivas, indicarão MAIOR preferência por diferenciação do que por conformidade.

H4: Expostos a motivações de longo prazo, indicarão MAIOR preferência por conformidade do que diferenciação.

Mensagens Testadas

Diferenciação:

"Destaque-se! Seja único! Experimente o que poucos têm coragem de fazer."

Conformidade: "Todo mundo está fazendo! Junte-se ao grupo! A escolha mais popular."

Resultados

Curto prazo:

Preferência por DIFERENCIAÇÃO (quero me destacar, ser único)

Longo prazo:

Preferência por CONFORMIDADE (quero pertencer ao grupo)

A motivação ativa diferentes estratégias de sinalização!

Construal Level Theory e Projetos

Distanciamento psicológico afeta a percepção de sucesso em projetos?

Construal Level Theory

Trope & Liberman (2010)

Quanto mais DISTANTE o objeto (tempo, espaço, social), mais ABSTRATA a representação.

Quanto mais PRÓXIMO, mais CONCRETA e detalhada.

Isso afeta julgamentos, preferências e decisões.

Design do Experimento

2 (distância: próximo/distante) $\times$ 2 (dimensão: geográfico/social)

Participantes: profissionais de grandes empresas que atuam em projetos.

Manipulação: cenários de condução de projeto.

Alocação aleatória + sorteio.

Ninguém sabia que havia 4 cenários diferentes.

Os Cenários de Manipulação

Distanciamento psicológico nas dimensões geográfica e social/cultural

Dimensão Geográfica

PRÓXIMO: "Todos da equipe trabalhavam no mesmo prédio e se reuniam presencialmente às quartas-feiras às 9h."

DISTANTE: "Todos da equipe trabalhavam em lugares diferentes e se reuniam virtualmente às quartas-feiras às 9h."

Dimensão Social/Cultural

PRÓXIMO: "Lugares diferentes com mesma nacionalidade, reunião virtual às quartas."

DISTANTE: "Lugares diferentes com nacionalidade diferente, reunião virtual às quartas."

Manipulation check: verificou se participantes entenderam.

Medidas

Após ler o cenário + manipulation check: questionário sobre probabilidade de sucesso do projeto em:

1. Prazo (entrega no tempo) 2. Custo (orçamento) 3. Escopo (entregas completas)

Hipóteses e Resultados — CLT

Próximo → maior percepção de sucesso em prazo, custo e escopo

Dimensão	Cenário	Prazo	Custo	Escopo
Geográfica	Próximo	> Probabilidade de Sucesso	> Probabilidade de Sucesso	> Probabilidade de Sucesso
	Distante	< Probabilidade de Sucesso	< Probabilidade de Sucesso	< Probabilidade de Sucesso
Social/Cultural	Próximo	> Probabilidade de Sucesso	> Probabilidade de Sucesso	> Probabilidade de Sucesso
	Distante	< Probabilidade de Sucesso	< Probabilidade de Sucesso	< Probabilidade de Sucesso

Odin Dinho

"Distância psicológica faz o projeto parecer mais abstrato — e menos provável de dar certo. Cenário simples, efeito forte."

Conectando Teoria e Desenho

Com base nos dois experimentos que acabamos de ver:

1. Identifique no experimento de Motivações Românticas:

- VI, VD, moderador, tipo de design
- Qual teste estatístico para H1? E para a interação gênero × prazo?

2. Identifique no experimento de CLT:

- VI, VD, manipulation check
- Por que sorteio sem que ninguém soubesse dos 4 cenários?
- Qual análise: teste t ou ANOVA?

3. Ambos usaram cenários como manipulação. Discuta:

- Vantagens e limitações de manipulação por cenário
- Como fortalecer a validade de construto?

Intervalo — 15 minutos

AULA 2 — BLOCO 7

Análise na Prática

Teste t, ANOVA, interações — usando nossos casos reais

Três Testes t: Qual Usar Quando?

Todos testam diferenças de médias, mas em contextos diferentes

t Independente

Compara 2 grupos independentes.
Cada participante em apenas uma condição.

Caso: Balas e gorjetas
(com vs. sem bala)

Caso: Romântico H1
(curto vs. longo, por gênero)

t Dependente (Pareado)

Compara o MESMO grupo em duas condições. Cada pessoa comparada consigo mesma.

Caso: Açúcar
(bolo X vs. bolo Y, mesma família)
Mais poder, menos N.

t de Uma Amostra

Compara uma amostra a um valor de referência.

Há um padrão conhecido?
A média difere dele?

Ex: "Satisfação média diferente de 3 (neutro)?"

Muninn

"Escolha o teste pela ESTRUTURA do dado, não pelo resultado que quer. O desenho define a análise."

JAMOVI e JASP: softwares gratuitos e visuais para executar testes t e ANOVA.

ANOVA: A Lógica Fundamental

Variância total = Variância between (sinal) + Variância within (ruído)

A Razão F

$F = MS_{\text{between}} / MS_{\text{within}}$

MS = Mean Square (variância)

Between = diferença entre grupos

Within = variação dentro dos grupos

Se F é grande: as médias dos grupos diferem mais do que o ruído esperaria por acaso.

No Churrasco (3×2)

Se as avaliações médias entre os métodos de preparo são MUITO diferentes (between grande) comparado à variação individual (within pequeno), o método tem efeito na percepção.

F grande → sinal > ruído

Pressupostos

1. Normalidade dos resíduos (Shapiro-Wilk por grupo — robusta com $N > 30$)
2. Homogeneidade de variâncias (Levene — se violado: Welch ANOVA)
3. Independência das observações (garantida pela randomização)

Shapiro-Wilk, Levene e Welch

Os testes que guardam os pressupostos da ANOVA

Shapiro-Wilk Samuel Shapiro e Martin Wilk (1965).

Testa se os dados seguem uma distribuição normal.

Se $p < .05$: normalidade violada.
Mas com $N > 30$, a ANOVA é robusta a essa violação (TCL).
Use por grupo, não no geral.

Levene Howard Levene (1960).

Testa se as variâncias são iguais entre os grupos (homogeneidade).

Se $p < .05$: variâncias desiguais.
Solução: usar Welch ANOVA em vez da ANOVA clássica.
Menos sensível que o Bartlett.

Welch Bernard Welch (1951).

Versão da ANOVA (e do teste t) que NÃO assume variâncias iguais.

Ajusta os graus de liberdade.
Alguns autores recomendam usar Welch SEMPRE, por precaução.
JAMOV e JASP calculam ambos.

ANOVA Fatorial: O Efeito de Interação

A interação é equivalente a uma moderação — o efeito de A depende de B

Efeitos de Interação = Moderação

Na ANOVA, interação $A \times B$.

Na regressão, termo $X \times W$.

A mesma coisa com nomes diferentes. Qualquer semelhança não é mera coincidência!

Quando $F(\text{interação})$ é sig.

1. Decompor em simple effects
2. Testar A em cada nível de B
3. Correção (Holm/Bonferroni)
4. Gráfico de interação
5. Efeitos principais isolados são ENGANOSOS com interação

Nos Nossos Casos Reais

Churrasco: efeito do método (gás vs. carvão) depende do corte (fraldinha $\neq$ picanha) $\rightarrow$ interação corte $\times$ método

Romântico: efeito do prazo (curto vs. longo) pode depender do gênero $\rightarrow$ interação prazo $\times$ gênero

CLT: efeito da distância pode depender da dimensão (geográfica vs. social) $\rightarrow$ interação distância $\times$ dimensão

Em todos os casos: decompor em simple effects!

Interpretando uma Interação 2×2

Tipo de incentivo (financeiro vs. social) $\times$ Tipo de tarefa (individual vs. grupo)

VD: produtividade (escala 0-100)

	Individual	Grupo
Financeiro	M = 72	M = 58
Social	M = 61	M = 75

1. Desenhe o gráfico de interação (linhas para cada tipo de incentivo)
2. A interação é ordinal ou disordinal? Justifique.
3. Quais simple effects você testaria?
4. Os efeitos principais isolados são informativos aqui? Por quê?
5. Escreva uma frase interpretando o padrão para um gestor.

AULA 2 — BLOCO 8

Effect Sizes, Power e Reporting

Porque p -value é só a porta de entrada

Cohen's d: Tamanho de Efeito para Diferenças de Médias

Quantas unidades de desvio padrão separam os dois grupos?

Fórmula e Interpretação

$$d = (M1 - M2) / SD_{\text{pooled}}$$

Pequeno: $d = 0.2$ a 0.5

Médio: $d = 0.5$ a 0.8

Grande: $d > 0.8$

Sempre com Intervalo de Confiança

$$d = 0.83, 95\% \text{ CI } [0.30, 1.36]$$

O IC diz a PRECISÃO.

Se inclui zero: compatível
com ausência de efeito.

Benchmarks ≠ Regras

Cohen (1988) propôs os benchmarks como REFERÊNCIA, não como lei. O contexto do domínio importa:

$d = 0.20$ pode ser enorme em saúde pública (milhões de pessoas).

$d = 0.80$ pode ser trivial se a intervenção custa milhões.

Hedges' g : versão corrigida para amostras pequenas — preferível quando $N < 20$.

Jacob Cohen & Larry Hedges

Os dois nomes por trás dos effect sizes mais usados em ciências sociais

Jacob Cohen (1923-1998)

Psicólogo e estatístico americano.

Criou o d de Cohen e os benchmarks (pequeno, médio, grande) em 1988.

Também criou o f de Cohen para ANOVA e o power analysis moderno.

Larry Hedges (1950-)

Northwestern University.

Criou o g de Hedges: correção do d para amostras pequenas.

Pioneiro em meta-análise.

Preferido quando $N < 20$.

d vs. g na Prática

$d = (M1 - M2) / SD_{\text{pooled}}$

$g = d \times J$ (fator de correção)

$J = 1 - 3 / (4 \cdot df - 1)$

Para $N > 20$: $d \approx g$.

Para $N < 20$: use g de Hedges.

Benchmarks de Cohen

Pequeno: $d = 0.20$

Médio: $d = 0.50$

Grande: $d = 0.80$

ATENÇÃO: são referências gerais, não critérios rígidos!

Eta-Quadrado: Tamanho de Efeito para ANOVA

Proporção da variância total explicada pela variável independente

Contexto	Effect Size	Pequeno	Médio	Grande
2 grupos	Cohen's d	0.20	0.50	0.80
ANOVA	η^2	≈ 0.01	≈ 0.06	≈ 0.14
ANOVA parcial	η^2_p	.01	.06	.14
Correlação	r	.10	.30	.50

η^2 na Prática

η^2 (eta ao quadrado): proporção da variância total da VD explicada pela VI.

Conforme sugerido por Cohen (1988): pequeno ≈ 0.01 , médio ≈ 0.06 , grande ≈ 0.14 .

η^2_p (parcial): variância explicada relativa à variância explicada + erro (mais comum em ANOVA fatorial).

Power: Encontrar o que Existe

$Power = 1 - \beta = P(\text{rejeitar } H_0 \text{ quando } H_0 \text{ é falsa})$

Alpha (α)

Risco de Tipo I.
Convenção: .05
Mais conservador: .01

Power ($1-\beta$)

Alvo: .80 (mínimo)
Ideal: .90
.80 = 20% chance de
perder o efeito

Effect Size

Da literatura ou
piloto. Não "chutar".
Converte $d \leftrightarrow f \leftrightarrow \eta^2$
conforme necessário

N (calcular!)

Determinar a priori.
G*Power ou R.
Nunca coletar até
achar $p < .05$

Huginn

"Para interações: multiplique o N dos efeitos principais por ~4. Interações exigem MUITO mais poder."

Precision for Planning (Cumming): alvo = MOE desejada, não power. Quanto menor a MOE, mais N.

G*Power, Geoff Cumming & MOE

Ferramentas e conceitos para planejar o tamanho amostral com rigor

G*Power

Software gratuito (Faul et al., 2007).
Calcula N necessário dados α , power e effect size esperado. Padrão-ouro para power analysis a priori.
Download: gpower.hhu.de

Geoff Cumming

Psicólogo australiano, autor de Understanding the New Statistics (2012).
Defende transição de NHST para estimação (CIs + effect sizes).
Criou os 8 passos da estimação.

MOE (Margin of Error)

Metade da largura do IC 95%.
 $MOE = IC_{sup} - IC_{inf} / 2$.
Quanto menor a MOE, mais precisa a estimativa.
MOE é controlada por N.

Precision for Planning

Alternativa ao power analysis.
Em vez de mirar power = .80, mire a MOE desejada.
Ex: quero $d \pm 0.15 \rightarrow$ preciso de N = 350 por grupo.

Reporting: Formato APA

Sempre: effect size + intervalo de confiança. Nunca: só p.

Teste t (independente)

Um teste t independente foi conduzido para comparar os escores entre Grupo A e Grupo B. Houve diferença significativa: $t(118) = -2.19$, $p = .030$, $d = 0.40$.

ANOVA

Uma ANOVA de um fator comparou os escores entre 3 grupos. $F(2, 117) = 1.27$, $p = .285$, $\eta^2 = .02$.
Médias: GA ($M = 2.50$, $DP = 1.12$), GB ($M = 2.70$)...

Manipulation Check

$t(118) = 7.89$, $p < .001$, $d = 1.44$.

Participantes na condição de tratamento perceberam conforme.

Interação + Simple Effects

$F(1, 196) = 8.90$, $p = .003$, $\eta^2 p = .04$.

Simple effects: financeiro em tarefa individual vs. grupo: $F(1,98) = \dots$

Regra de Ouro

M, DP (ou SD), teste estatístico com df, valor de p (exato quando possível), effect size com IC 95%.

APA: Formato de Reporting Padrão

American Psychological Association — o padrão em psicologia e administração

O que é a APA?

Fundada em 1892, é a maior associação de psicólogos do mundo. Publica o Publication Manual (7a ed.) que padroniza escrita acadêmica em psicologia e áreas correlatas.

Por que usar formato APA?

Padronização universal: qualquer leitor sabe onde encontrar cada info.
Exige: estatística de teste, df, p exato, effect size + IC 95%.
Transparência e replicabilidade.

Escrevendo Resultados em APA

Com os dados do experimento de Motivações Românticas:

Design 2 (prazo: curto vs. longo) x 2 (gênero: H vs. M), between-subjects.

VD: ranking de risco da atividade esportiva escolhida (1-10).

Dados fictícios para prática:

Homens curto prazo: $M = 7.2$, $DP = 1.8$

Homens longo prazo: $M = 4.5$, $DP = 2.1$

Mulheres curto prazo: $M = 6.8$, $DP = 1.6$

Mulheres longo prazo: $M = 5.1$, $DP = 1.9$

1. Calcule o d de Cohen para homens (curto vs. longo prazo)
2. Escreva o resultado do teste t para $H1$ em formato APA
3. A ANOVA 2x2 deu: $F(1, 196) = 4.52$, $p = .035$, $\eta^2p = .02$

Escreva a interpretação da interação e os simple effects

Os Pecados Capitais de ThorMento

O que NÃO fazer no seu experimento

P-Hacking

Rodar 50 testes e reportar apenas os significativos.
Odin diz: pré-registre.

HARKing

Inventar hipóteses depois de ver os resultados.
Odin diz: separe exploratório de confirmatório.

Sem Manip. Check

Assumir que a manipulação funcionou sem verificar.
Odin diz: sempre meça.

N Insuficiente

Coletar até achar $p < .05$.
Odin diz: calcule N a priori com G*Power.

Sem Effect Size

Reportar apenas p-value.
Odin diz: p é a porta, ES é a sala inteira.

Confounds Ignorados

Não randomizar, não controlar, não discutir.
Odin diz: randomize ou argumente.

HARKing, P-Hacking & QRPs

As práticas questionáveis de pesquisa que ThorMento adora

HARKing

Hypothesizing After Results are Known (Kerr, 1998).
Inventar hipóteses DEPOIS de ver os dados e apresentá-las como se fossem a priori.

P-Hacking

Manipular análises até obter $p < .05$: excluir outliers seletivamente, testar múltiplas VDs, parar coleta ao atingir significância (Simmons et al., 2011).

QRPs

Questionable Research Practices.
Termo guarda-chuva para todas as práticas que inflam falsos positivos: HARKing, p-hacking, não reportar estudos nulos, etc.

Antídotos

Pré-registro (OSF, AsPredicted)
Separar exploratório/confirmatório
Reportar TODOS os resultados
Usar effect sizes + CIs
Replicação direta

Checklist do Experimento Bem Feito

- Pergunta de pesquisa com relação causal clara
- Desenho coerente com a hipótese (fatorial? within? mixed?)
- Manipulação operacionalizada e pré-testada
- Manipulation check incluído
- Randomização descrita (método + software)
- Power analysis a priori (N justificado)
- Pressupostos verificados (normalidade, Levene, esfericidade)
- Effect sizes reportados com intervalos de confiança
- Interações decompostas em simple effects
- Ameaças à validade discutidas com nuance
- Pré-registro (OSF ou AsPredicted)

Avaliando um Experimento

Leiam o resumo e avaliem usando o checklist:

Um estudo com 45 estudantes (22 no grupo experimental, 23 no controle) testou o efeito de storytelling (vs. dados estatísticos) sobre persuasão. Between-subjects. Participantes leram um texto persuasivo sobre doações e responderam uma escala de atitude (1-7). Resultado: $t(43) = 2.12$, $p = .039$. Conclusão dos autores: storytelling é mais persuasivo que dados estatísticos.

Avaliem:

1. O que está bom neste estudo?
2. O que está faltando? (use o checklist)
3. O N é adequado? Calcule o power post-hoc para $d = 0.50$.
4. O p-value é convincente sem effect size e CI?
5. Proponham 3 melhorias prioritárias.

De acordo com a escala de importância, as

Quasi-Experimentos: Quando Não Há Randomização

Designs válidos quando a randomização é impossível ou antiética

Nonequivalent Control

Grupos pré-existentes.
Ameaça central: seleção.
Mitigação: ANCOVA com
pré-teste, propensity score.

Difference-in-Differences

Compara mudança pré-pós
entre tratado e controle.
Pressuposto: parallel trends.
Testável com dados pré.

Regression Discontinuity

Threshold determina tratamento.
Ex: nota > 7 = bolsa.
Inferência forte PERTO do cutoff.
Requer running variable contínua.

Interrupted Time Series

Múltiplas medidas antes e depois.
Separa tendência de efeito.
Ideal: 8+ pontos pré e pós.
Análise: segmented regression.

Odin Dinho

"Quasi-experimentos são válidos quando bem argumentados. Mas exigem transparência sobre as limitações."

DiD, RDD, ANCOVA & MANOVA

Técnicas avançadas mencionadas em quasi-experimentos e análise multivariada

DiD (Diff-in-Differences)

Compara a MUDANÇA (pré vs pós) entre grupo tratado e controle.
Pressuposto: tendências paralelas.
Nobel 2021 (Card, Angrist, Imbens).

RDD (Regression Discont.)

Tratamento atribuído por threshold (ex: nota > 7 = bolsa). Compara observações perto do cutoff.
Validade interna forte próximo ao ponto de corte.

ANCOVA

Analysis of Covariance.
ANOVA + covariável contínua (ex: pré-teste). Remove variância do erro, aumentando poder.
Pressuposto: homogeneidade.

MANOVA

Multivariate ANOVA.
Múltiplas VDs simultâneas.
Controla inflação de erro Tipo I.
Testes: Pillai, Wilks, Hotelling.

Lição dos Corvos — Encerramento

Muninn — Resumo das Duas Aulas

Experimento = causalidade por desenho

3 casos reais: balas (between),
açúcar (within), churrasco (fatorial)

Psicologia evolucionista gera
hipóteses testáveis

Romântico: risco + diferenciação
CLT: distância → percepção

ANOVA decompõe variância;
interação é o coração do fatorial

Effect size + CI > p-value

Huginn — Desafios Finais

1. Desenhem um experimento para sua pesquisa
2. Calculem o N necessário (G*Power ou R)
3. Escrevam o método completo em formato APA
4. Pré-registrem no OSF (osf.io/prereg)
5. Usem os Simuladores interativos e o FAQ com 100 perguntas no site!

osf.io | aspredicted.org

Referências Essenciais

- Shadish, W., Cook, T. & Campbell, D. (2002). Experimental and Quasi-Experimental Designs for Generalized Causal Inference.
- Field, A. & Hole, G. (2003). How to Design and Report Experiments. Sage.
- Hayes, A.F. (2018). Introduction to Mediation, Moderation, and Conditional Process Analysis. 2nd ed.
- Cumming, G. (2012). Understanding the New Statistics. Routledge.
- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences. 2nd ed.
- Trivers, R. (1972). Parental Investment and Sexual Selection. In B. Campbell (Ed.).
- Trope, Y. & Liberman, N. (2010). Construal-Level Theory of Psychological Distance. Psych. Review.
- Hernandez, J.M.C., Basso, K. & Brandão, M.M. (2014). Pesquisa Experimental em Marketing. REMark.
- Buss, D.M. (2019). Evolutionary Psychology. 6th ed. Routledge.